

POS TECH · TECH CHALLENGE · FASE 1

Sistema inteligente de suporte ao diagnóstico

Machine Learning aplicado à análise de exames médicos

Repositório Git:	https://github.com/SEU-USUARIO/SEU-REPOSITORIO
Vídeo (até 15 min):	https://youtu.be/SEU-VIDEO
Integrantes:	(preencher com os integrantes do grupo)
Data:	02/09/2026
Modelo campeão:	Regressao Logistica
Resultado no teste:	recall 0.9762 · F1 0.9111 · ROC AUC 0.996

O modelo prioriza. O médico diagnostica.

Tarefa principal: diagnóstico de câncer de mama (Breast Cancer Wisconsin).
Entregável EXTRA: detecção de pneumonia em radiografias de tórax com CNN.

Relatório Técnico — Tech Challenge, Fase 1

Sistema inteligente de suporte ao diagnóstico

Tarefa principal: classificação de biópsias mamárias (maligno × benigno) a partir de dados tabulares.

Entregável EXTRA: detecção de pneumonia em radiografias de tórax com rede neural convolucional.

Todos os números deste relatório foram produzidos por `python scripts/run_pipeline.py` (semente 42, 285 s de execução) e por `python scripts/run_cnn.py --epochs 15 --size 64`. As tabelas de origem estão em `reports/metrics/` e as figuras em `reports/figures/`.

Sumário

1. [O problema e por que ele importa](#)
 2. [Dados e exploração](#)
 3. [Estratégias de pré-processamento](#)
 4. [Modelos usados e por quê](#)
 5. [Treinamento e seleção do campeão](#)
 6. [Escolha da métrica e calibração do limiar](#)
 7. [Resultados no conjunto de teste](#)
 8. [Interpretação dos resultados](#)
 9. [Robustez e análise de erros](#)
 10. [EXTRA — visão computacional](#)
 11. [Discussão crítica: dá para usar na prática?](#)
 12. [Conclusão](#)
-

1. O problema e por que ele importa

O hospital universitário recebe mais exames do que a equipe de patologia consegue laudar no mesmo dia. A consequência não é apenas atraso administrativo: é que **um carcinoma agressivo pode ficar semanas na fila atrás de dezenas de nódulos benignos**, e a janela terapêutica se estreita.

O objetivo desta fase, portanto, **não é automatizar o diagnóstico**. É construir a base de um sistema que:

1. atribua a cada exame uma **probabilidade de malignidade**;
2. traduza essa probabilidade em uma **faixa de triagem** operacional;
3. **explique** por que chegou àquele número, para que o médico possa concordar ou discordar de forma fundamentada.

O sucesso não se mede por "acurácia alta". Mede-se por **quantos cânceres deixam de esperar** — sem que o sistema vire um alarme que ninguém escuta.

2. Dados e exploração

2.1 A base

Breast Cancer Wisconsin (Diagnostic) — WDBC. 569 biópsias por punção aspirativa por agulha fina (PAAF) de nódulo mamário. Cada registro traz 30 atributos morfométricos extraídos digitalmente da imagem do núcleo celular: 10 medidas (raio, textura, perímetro, área, suavidade, compactidade, concavidade, pontos côncavos, simetria, dimensão fractal) × 3 estatísticas (`_mean` , `_se` , `_worst`).

Por que este dataset. É a base tabular indicada no enunciado, é pública e auditável, e — decisivo — as variáveis têm **significado clínico direto**: são medidas de atipia nuclear, exatamente o que o patologista avalia. Um modelo que se apoia nelas produz explicações que a equipe médica consegue criticar, em vez de correlações opacas.

2.2 Auditoria de qualidade

Antes de qualquer modelagem (`reports/metrics/01_auditoria_dataset.json`):

verificação	resultado
dimensões	569 linhas × 31 colunas (30 preditoras + alvo)
valores ausentes	0
linhas duplicadas	0
colunas constantes	nenhuma
zeros biologicamente impossíveis (raio/perímetro/área/textura = 0)	nenhum
distribuição do alvo	357 benignos (62,74%) / 212 malignos (37,26%)
razão de desbalanceamento	1,684 : 1

A verificação de "zeros impossíveis" não é burocracia: em bases clínicas, um `0` costuma ser **ausência disfarçada de valor**. Um núcleo celular com área zero não existe. Aqui, nenhum caso — a base é genuinamente limpa.

2.3 O que a exploração mostrou

Desbalanceamento leve, mas suficiente para invalidar a acurácia. 1,68:1 não exige reamostragem. Exige, sim, abandonar a acurácia como métrica principal: um classificador que responde sempre "benigno" já acerta **62,74%** — sem detectar um único câncer. (fig. `01_balanceamento_classes.png`)

As classes se separam nitidamente nas variáveis `_worst`. Para `concave_points_worst` , `perimeter_worst` e `radius_worst` , as duas distribuições quase não se sobrepõem: tumores malignos têm núcleos maiores, mais irregulares e com mais reentrâncias no contorno. Isso é coerente com o critério histopatológico de atipia nuclear — sinal de que o modelo aprenderá algo real, e não um artefato do dataset. (figs. `02_distribuicoes_por_classe.png` , `03_boxplots_por_classe.png`)

As escalas diferem em mais de três ordens de grandeza. `area_worst` chega a ~4.250; `fractal_dimension_se` fica na casa de 0,003. Além disso, várias variáveis têm assimetria positiva forte (`|skew|`

> 1). Isso define duas decisões de pré-processamento — padronizar e imputar pela mediana — e não é opcional para KNN, SVM e para a regularização da regressão logística. (fig. 08_escala_e_assimetria.png)

O problema é quase linearmente separável. Duas componentes principais concentram ~63% da variância e já separam visualmente as classes. Essa é uma expectativa importante: **se um modelo complexo não superar a regressão logística por margem relevante, devemos ficar com o modelo simples.** (fig. 06_projecao_pca.png)

2.4 Análise de correlação

Duas perguntas distintas, respondidas separadamente:

(a) O que se associa ao diagnóstico? (03_correlacao_com_alvo.csv)

variável	correlação ponto-bisserial com o alvo
concave_points_worst	0,794
perimeter_worst	0,783
concave_points_mean	0,777
radius_worst	0,777
perimeter_mean	0,743

(b) O que é redundante entre si? (04_pares_redundantes.csv)

21 pares com $|r| \geq 0,90$. Os blocos são previsíveis pela geometria: `radius`, `perimeter` e `area` medem a mesma coisa ($r > 0,98$), e o mesmo vale entre `concavity` e `concave_points`. O procedimento marcou **10 colunas** como candidatas a descarte.

Decisão: manter as 30 variáveis. A multicolinearidade não prejudica árvores, SVM ou KNN; ela desestabiliza a interpretação dos coeficientes lineares, pois o peso de uma variável "vaza" para a gêmea. O antídoto adotado foi **regularização L2** (que distribui o peso entre as colineares em vez de escolher uma arbitrariamente) somado a uma interpretação que **não depende só dos coeficientes** — permutação e SHAP. (figs. 04_matriz_correlacao.png, 05_correlacao_com_alvo.png)

3. Estratégias de pré-processamento

Todo o pré-processamento vive **dentro** de um `sklearn.Pipeline`. Isso não é preferência de estilo — é o que impede o erro mais comum e mais silencioso da área: **vazamento de dados**. A média e o desvio usados na padronização são aprendidos *somente* no conjunto de treino e depois aplicados à validação e ao teste. Calculá-los sobre a base inteira inflaria as métricas sem que nada quebre.

etapa	decisão	justificativa
identificador	<code>id</code> descartado	é número de prontuário; não carrega informação clínica
alvo	<code>M → 1, B → 0</code>	maligno é a classe positiva — o evento clinicamente crítico
ausentes (numéricos)	imputação pela mediana	resistente à assimetria e aos outliers das caudas longas; a média seria puxada pelos tumores extremos
ausentes (categóricos)	imputação pela moda	preserva a categoria mais provável
categóricos	<code>OneHotEncoder(handle_unknown="ignore")</code>	uma categoria nunca vista em produção não pode derrubar o serviço
escala	<code>StandardScaler</code> (z-score)	escalas diferem em >3 ordens de grandeza
multicolinearidade	mantida, controlada por regularização L2	descartar colunas perderia informação real

Sobre o ramo categórico

O `ColumnTransformer` tem **dois ramos automáticos**, resolvidos em tempo de `fit` pelo tipo de cada coluna. No WDBC as 30 preditoras são numéricas, então **o ramo categórico fica vazio nesta execução** — e isso está explicitamente documentado, não escondido.

Ele é mantido porque o mesmo pipeline atende as demais bases do hospital (sexo, etnia, unidade de origem, tipo de exame) sem uma linha de alteração. O teste automatizado `test_ramo_categorico_funciona_com_dados_mistos` alimenta o pré-processador com um quadro misto contendo `NaN` e uma categoria inédita, e verifica que a saída sai numérica, completa e com a dimensão correta.

Prova de que a imputação funciona

Como a base não tem ausentes, o ramo de imputação ficaria sem exercício. Para não entregar código não verificado, injetamos ausências MCAR no conjunto de teste e medimos a degradação — resultados na [seção 9](#).

Separação treino / validação / teste

Três partições **estratificadas**, com papéis rigidamente separados (`06_particoes.csv`):

partição	n	%	benignos	malignos	prevalência	papel
treino	341	59,9%	214	127	37,24%	ajuste + busca de hiperparâmetros (CV 5 folds)
validação	114	20,0%	71	43	37,72%	seleção do campeão + calibração do limiar
teste	114	20,0%	72	42	36,84%	aberto uma única vez , ao final

A estratificação preserva a prevalência de malignos nas três partições. Sem ela, com apenas 569 amostras, uma partição poderia ficar com prevalência bem diferente e distorcer toda a avaliação.

4. Modelos usados e por quê

Seis famílias, escolhidas para cobrir hipóteses **estruturalmente diferentes** sobre a forma da fronteira de decisão — não para engordar a lista.

modelo	hipótese que testa	por que está aqui
Regressão Logística (L2, liblinear)	fronteira linear no espaço padronizado	Padrão-ouro em estatística médica: os coeficientes viram razões de chance , grandeza que a equipe clínica já interpreta. É o modelo mais fácil de auditar e de defender perante um comitê de ética.
Árvore de Decisão	regras de corte em variáveis isoladas	Produce regras explícitas ("se <code>radius_worst > 16,8</code> então suspeitar"), o mais próximo de um protocolo clínico escrito. Sozinha é instável — serve de referência de interpretabilidade máxima.
KNN	separação local por semelhança	Raciocínio por analogia: classifica o paciente pelos casos históricos mais parecidos. Testa se a estrutura do problema é local ou global.
Random Forest	interações não lineares, votação de árvores decorrelacionadas	Absorve bem a multicolinearidade, é robusto a outliers e fornece importância nativa + SHAP exato via <code>TreeExplainer</code> .
Gradient Boosting	correção sequencial de resíduos	Costuma ser o teto de desempenho em dados tabulares. Serve para verificar se os modelos simples já saturaram o problema.
SVM (kernel RBF)	margem máxima em espaço de alta dimensão	Historicamente muito forte em bases <i>pequenas e largas</i> (569 × 30). Envolvido em <code>CalibratedClassifierCV</code> (Platt scaling) porque o SVC devolve distâncias à margem, não probabilidades — e nosso limiar clínico opera sobre probabilidade.

5. Treinamento e seleção do campeão

5.1 Busca de hiperparâmetros

`GridSearchCV` com `StratifiedKFold` de 5 dobras, **apenas no conjunto de treino**.

A métrica de *refit* é a **ROC AUC**, e a escolha é deliberada: ela **independe do limiar de decisão** e mede a capacidade de ordenar corretamente os pacientes por risco — exatamente o que a triagem precisa. Otimizar recall diretamente na busca levaria à solução degenerada de classificar todo mundo como maligno (recall 1,0, clinicamente inútil). **O limiar é calibrado depois, separadamente.**

Resultados da validação cruzada no treino (`07_resultados_validacao_cruzada.csv`):

modelo	ROC AUC (CV)	desvio	recall	precisão	F1	acurácia
Regressão Logística	0,9944	0,0075	0,9609	0,9683	0,9645	0,9736
SVM (RBF)	0,9941	0,0083	0,9532	0,9757	0,9641	0,9737
Gradient Boosting	0,9929	0,0064	0,9375	0,9766	0,9549	0,9679
Random Forest	0,9884	0,0117	0,9535	0,9510	0,9500	0,9619
KNN	0,9859	0,0141	0,8831	0,9694	0,9201	0,9445
Árvore de Decisão	0,9814	0,0124	0,9603	0,9019	0,9282	0,9443

5.2 O critério de seleção — e por que não é o óbvio

A primeira versão deste pipeline escolhia o campeão pela **ROC AUC do conjunto de validação**. O resultado foi o KNN — que era o **penúltimo colocado na validação cruzada** e terminou com desempenho inferior no teste.

O diagnóstico é direto: com 114 exames de validação (43 malignos), o erro-padrão da AUC beira $\pm 0,02$. **Um modelo pode "vencer" por sorte de partição.**

O critério final é a **média entre duas estimativas independentes de ROC AUC**:

$$\text{score_seleção} = 0,5 \times \text{ROC_AUC}(\text{CV 5-fold no treino}) + 0,5 \times \text{ROC_AUC}(\text{holdout de validação})$$

↑ estabilidade (341 amostras)

↑ confirmação independente

Nenhuma das duas toca o conjunto de teste. Resultado (`08b_ranking_selecao_campeao.csv`):

modelo	ROC AUC CV	ROC AUC validação	score de seleção
Regressão Logística	0,9944	0,9957	0,99510
SVM (RBF)	0,9941	0,9957	0,99491
Gradient Boosting	0,9929	0,9934	0,99317
KNN	0,9859	0,9974	0,99163
Random Forest	0,9884	0,9902	0,98928
Árvore de Decisão	0,9814	0,9687	0,97507

Campeão: Regressão Logística (`C = 1,0` , penalidade L2, sem reponderação de classe). Diferença para o SVM: 0,0002 — estatisticamente indistinguível.

Esse empate técnico é o resultado mais importante da modelagem. Quando o modelo mais simples e mais auditável empata com o mais complexo, a escolha em medicina é óbvia: fica o que a equipe clínica consegue ler, contestar e homologar. A expectativa levantada na PCA (problema quase linearmente separável) se confirmou.

(figs. `09_comparacao_modelos.png` , `10_curvas_roc_pr.png` , `16_curva_aprendizado.png`)

6. Escolha da métrica e calibração do limiar

6.1 Por que recall, e não acurácia

Os dois erros têm custos **radicalmente assimétricos**:

erro	consequência clínica	reversível?
Falso negativo — câncer classificado como benigno	a paciente é liberada, o tumor evolui, a janela terapêutica se fecha	não
Falso positivo — benigno marcado como suspeito	ansiedade + biópsia excisional confirmatória	sim

Logo:

- **métrica que governa a operação: recall (sensibilidade) da classe maligna;**
- **F1 e precisão como contrapeso**, para o sistema não virar um alarme que ninguém escuta;
- **ROC AUC / PR AUC** para comparar modelos independentemente do limiar;
- **acurácia relatada, mas nunca como critério** — 62,74% é o piso trivial.

6.2 O limiar como parâmetro clínico

O limiar padrão de 0,50 não tem nada de especial: é uma convenção matemática, não uma decisão médica. Nosso procedimento (`evaluate.tune_threshold`) faz o contrário:

1. fixa a **sensibilidade mínima aceitável** (99%, definida como requisito clínico);
2. entre **todos** os limiares que a atendem na validação, escolhe **o mais alto** — porque esse é o que minimiza biópsias desnecessárias.

Resultado na validação: **limiar = 0,0934**, com recall 1,000 (43/43) e precisão 0,768. (fig. `11_analise_limiar.png`, tabela `09_curva_limiar_validacao.csv`)

Limitação honesta e relevante. Com apenas 43 malignos na validação, a granularidade do recall é $1/43 \approx 0,023$. Exigir $\geq 0,99$ força, na prática, **recall perfeito na validação** — e recall perfeito em 43 casos não se transfere automaticamente. Foi exatamente o que aconteceu: no teste, o mesmo limiar entrega 0,976 (41/42). O limiar deve ser **re-derivado sobre uma amostra prospectiva maior** antes de qualquer uso real; o valor aqui é uma demonstração do método, não uma recomendação operacional.

7. Resultados no conjunto de teste

O campeão foi reajustado em **treino + validação** (455 exames) para aproveitar todos os dados disponíveis. Hiperparâmetros e limiar já estavam **congelados**, portanto não há vazamento. Só então o teste foi aberto — **uma única vez**.

7.1 Regressão Logística nos 114 exames de teste

métrica	limiar padrão 0,50	limiar clínico 0,0934
Recall (sensibilidade)	0,9524	0,9762
Precisão (VPP)	0,9756	0,8542
Especificidade	0,9861	0,9028
F1-score	0,9639	0,9111
Acurácia	0,9737	0,9298
Acurácia balanceada	0,9692	0,9395
MCC	0,9433	0,8592
ROC AUC	0,9960	0,9960
PR AUC	0,9943	0,9943
Brier score	0,0211	0,0211
Verdadeiros positivos	40	41
Falsos negativos [△]	2	1
Falsos positivos	1	7
Verdadeiros negativos	71	65

(figs. [12_matriz_confusao_padrao.png](#), [13_matriz_confusao_clinica.png](#), [14_distribuicao_scores.png](#))

Como ler esta tabela. Baixar o limiar de 0,50 para 0,0934 troca **1 falso negativo por 6 falsos positivos**. Em números clínicos: um câncer a mais detectado ao custo de seis biópsias confirmatórias adicionais. Essa é uma decisão **do comitê clínico**, não do time de dados — o código apenas expõe o botão e mostra o preço de cada posição.

7.2 Todos os modelos no teste (limiar 0,50, para referência)

modelo	recall	F1	precisão	especificidade	acurácia	ROC AUC
Random Forest	0,9762	0,9762	0,9762	0,9861	0,9825	0,9987
SVM (RBF)	0,9762	0,9762	0,9762	0,9861	0,9825	0,9957
Regressão Logística (campeão)	0,9524	0,9639	0,9756	0,9861	0,9737	0,9954
KNN	0,9286	0,9512	0,9750	0,9861	0,9649	0,9974
Árvore de Decisão	0,9286	0,9176	0,9070	0,9444	0,9386	0,9906
Gradient Boosting	0,9048	0,9500	1,0000	1,0000	0,9649	0,9937

Uma observação de honestidade metodológica. Random Forest e SVM tiveram desempenho ligeiramente superior *neste* conjunto de teste. Isso **não invalida a escolha do campeão** — invalidaria o contrário: trocar o modelo depois de ver o teste seria exatamente o vazamento que a separação em três partições existe para evitar. A diferença (2 erros em 114 exames) está dentro do ruído amostral, e as seis famílias ficam entre 0,99 e 1,00 de ROC AUC.

7.3 Calibração das probabilidades

O **Brier score de 0,0211** e a curva de confiabilidade indicam que a probabilidade prevista é interpretável como risco, e não apenas como um ranking. Isso é o que legitima o uso de faixas de triagem e a comunicação de "probabilidade de malignidade" ao médico. (fig. 15_calibracao.png)

7.4 Faixas de triagem aplicadas ao teste

faixa	critério	n de exames	conduta
● VERDE	score < 0,0934	66	fila de rotina
● AMARELO	$0,0934 \leq \text{score} < 0,90$	15	revisão humana prioritária
● VERMELHO	score $\geq 0,90$	33	encaminhamento imediato

É assim que o ganho aparece na prática: 33 exames sobem imediatamente na fila, 15 são marcados como zona de incerteza e recebem atenção humana explícita, e 66 seguem o rito normal.

8. Interpretação dos resultados

Um modelo que não explica a própria decisão não é adotável em medicina. Usamos **três lentes complementares**, que respondem a perguntas diferentes.

8.1 Coeficientes — razões de chance (17_referencia_logistica_odds_ratio.csv)

Como as variáveis estão padronizadas, $\exp(\text{coeficiente})$ é a **razão de chances por aumento de 1 desvio-padrão** na variável.

variável	coeficiente	odds ratio por 1 DP	leitura
texture_worst	+1,424	4,15×	núcleos de textura mais heterogênea multiplicam por 4 a chance de malignidade
radius_se	+1,244	3,47×	variabilidade do raio entre núcleos — pleomorfismo celular
symmetry_worst	+1,059	2,88×	assimetria nuclear
concave_points_mean	+0,955	2,60×	reentrâncias no contorno
area_se	+0,933	2,54×	variabilidade da área
area_worst	+0,924	2,52×	tamanho dos maiores núcleos
compactness_se	-0,916	0,40×	efeito protetor condicional (ver abaixo)

(fig. 18_referencia_logistica.png)

8.2 Importância por permutação (14_importancia_permutacao.csv)

Embaralha uma variável por vez no conjunto de teste e mede a **queda real de ROC AUC**. Responde: "o que o modelo de fato usa?"

variável	queda média de ROC AUC	desvio
symmetry_worst	0,00984	0,00262
texture_worst	0,00860	0,00416
concavity_worst	0,00780	0,00268
concave_points_mean	0,00288	0,00229
concave_points_worst	0,00281	0,00150

As quedas são pequenas em termos absolutos — **e isso é informação, não ruído**: com 21 pares de variáveis quase idênticas, embaralhar uma delas quase não machuca, porque a gêmea continua ali. É a assinatura numérica da redundância detectada na EDA.

(fig. 19_importancia_permutacao.png)

8.3 SHAP (15_importancia_shap.csv)

Decompõe **cada previsão individual** na contribuição de cada variável (valores de Shapley). É a única das três lentes que explica **um paciente específico**.

variável	SHAP médio
texture_worst	0,0624
concave_points_mean	0,0459
symmetry_worst	0,0410
concavity_worst	0,0392
radius_se	0,0381

O gráfico *beeswarm* mostra magnitude **e direção**: valores altos (vermelho) dessas variáveis empurram consistentemente o score para a direita, isto é, para maligno. (figs. 20_shap_beeswarm.png, 21_shap_importancia_global.png)

8.4 Convergência — e uma divergência instrutiva

As três lentes convergem em texture_worst, symmetry_worst, concave_points_mean e concavity_worst. Mas há uma **divergência que vale a pena não varrer para debaixo do tapete**:

- na **correlação bruta** com o alvo, a campeã é concave_points_worst ($r = 0,794$), enquanto texture_worst aparece bem abaixo;
- no **modelo**, texture_worst é a variável de maior peso.

Não é contradição: são perguntas diferentes. A correlação mede a associação **marginal** (a variável sozinha). O coeficiente mede a contribuição **condicional** (o que ela acrescenta *dado que as outras 29 já estão no modelo*). Como concave_points_worst é quase redundante com metade da tabela, sua informação já foi absorvida; texture_worst, que mede outra coisa — heterogeneidade da cromatina —, traz informação **nova**.

O mesmo raciocínio explica o coeficiente negativo de compactness_se: não é que compactidade proteja contra câncer, e sim que, **fixadas** concavidade e pontos côncavos, o que sobra de compactness_se funciona

como correção. **É por isso que o relatório não se apoia só nos coeficientes** — e é exatamente esse tipo de nuance que precisa ser comunicado ao médico, e não escondido atrás de um ranking bonito.

8.5 Explicações individuais

Para quatro perfis de caso — verdadeiro positivo confiante, falso positivo, falso negativo e caso ambíguo — geramos o gráfico em cascata SHAP (`22_1..22_4_shap_caso_*.png`). **É esse gráfico que entra no laudo de apoio**: mostra, para aquele paciente, quais medidas empurraram o score para cima e quais o puxaram para baixo. É o que permite ao médico discordar de forma fundamentada — por exemplo, ao notar que o modelo se apoiou em uma medida afetada por artefato de preparo da lâmina.

9. Robustez e análise de erros

9.1 Degradação com dados ausentes (`16_robustez_dados_ausentes.csv`)

O WDBC não tem ausentes; um prontuário hospitalar real chega incompleto. Injetamos ausências MCAR no conjunto de teste e medimos:

% de células ausentes	recall	precisão	F1	ROC AUC	falsos negativos
0%	0,9762	0,8542	0,9111	0,9960	1
5%	0,9762	0,8913	0,9318	0,9960	1
10%	0,9762	0,9111	0,9425	0,9950	1
20%	0,9524	0,8696	0,9091	0,9901	2

Leitura. Até 10% de campos ausentes o recall não se move e a ROC AUC cai 0,001 — a imputação pela mediana sustenta bem a degradação, novamente graças à redundância entre as variáveis. Aos 20%, o recall cai e aparece um segundo falso negativo. **Recomendação operacional: o serviço deve recusar (ou marcar como "não conclusivo") qualquer exame com mais de ~10% de campos faltantes**, em vez de devolver um score silenciosamente pior.

9.2 Onde o modelo erra (`12_analise_de_erros_teste.csv`)

No limiar clínico, 8 dos 114 exames de teste foram classificados errado: **7 falsos positivos e 1 falso negativo**.

- Os falsos positivos concentram-se em scores entre 0,09 e 0,51 — ou seja, **quase todos caíam na faixa AMARELO**, que já prevê revisão humana. O sistema não os afirma como malignos; ele os marca como incertos, que é o comportamento desejado.
- O único falso negativo tem score 0,0635, **abaixo mas próximo do limiar de 0,0934**. Sua explicação SHAP (`22_1_shap_caso_falso_negativo.png`) mostra um tumor com morfometria atipicamente discreta — o tipo de caso que também desafia o observador humano.

10. EXTRA — visão computacional

10.1 Dados

PneumoniaMNIST (MedMNIST v2): versão padronizada e curada do *Chest X-Ray Pneumonia* de Kermany et al. — a mesma base indicada no enunciado, porém já dividida em treino/validação/teste pelos autores, sem exigir credenciais do Kaggle.

partição	n	% pneumonia
treino	4.708	74,2%
validação	524	74,2%
teste	624	62,5%

Resolução usada: **64 × 64**, em escala de cinza (`--size 64`). (fig. `30_amostras_radiografias.png`)

Note o **deslocamento de prevalência** entre validação (74,2%) e teste (62,5%). Isso é proposital nos dados originais e é uma boa notícia metodológica: qualquer limiar calibrado na validação é testado sob uma distribuição diferente — mais parecido com a realidade de implantação.

10.2 Arquitetura e treinamento

CNN compacta treinada do zero: **3 blocos** `Conv3×3 → BatchNorm → ReLU → Conv3×3 → BatchNorm → ReLU → MaxPool` (32 → 64 → 128 canais), `AdaptiveAvgPool` e cabeça densa com dropout. **295.201 parâmetros treináveis** — pequena o suficiente para treinar em CPU.

Decisões relevantes:

- **Data augmentation** (espelhamento horizontal, rotações de $\pm 8^\circ$, translações e escala de $\pm 5\%$) — simula variações reais de posicionamento do paciente no aparelho.
- `BCEWithLogitsLoss` com `pos_weight` — a base é desbalanceada (74% pneumonia), e o peso corrige o viés da perda.
- **Seleção de época pela ROC AUC de validação**, não pela acurácia — em base desbalanceada, a acurácia sobe simplesmente por prever a classe majoritária.
- `AdaptiveAvgPool2d` torna a rede independente da resolução: treinar em 28×28 ou 128×128 não exige alterar o código.

(fig. `31_cnn_curvas_treino.png`)

10.3 Resultados

Treino de 15 épocas em CPU (1.094 s). Melhor época: **14**, com **ROC AUC de validação 0,9969**. Avaliação nos 624 exames do conjunto de teste oficial (`20_metricas_cnn_teste.csv`):

métrica	limiar padrão 0,50	limiar clínico 0,194
Recall (sensibilidade)	0,9821	0,9872
Precisão	0,8949	0,8575
Especificidade	0,8077	0,7265
F1-score	0,9364	0,9178
Acurácia	0,9167	0,8894
Acurácia balanceada	0,8949	0,8568
ROC AUC	0,9709	0,9709
PR AUC	0,9801	0,9801
MCC	0,8237	0,7691
Verdadeiros positivos	383	385
Falsos negativos $\triangle$	7	5
Falsos positivos	45	64
Verdadeiros negativos	189	170

Recall de 98,7% com 295 mil parâmetros treinados do zero em CPU — sem transfer learning, sem GPU. Para uma primeira triagem radiológica, sinalizar 385 dos 390 casos de pneumonia é um resultado sólido.

A observação mais instrutiva desta seção: a AUC caiu de 0,9969 na validação para 0,9709 no teste. Isso **não é overfitting no sentido usual** — a curva de treino não descolou da de validação. É **deslocamento de distribuição**: o conjunto de teste do PneumoniaMNIST tem prevalência de 62,5% contra 74,2% da validação, e vem de uma coorte diferente. A especificidade sofre mais que o recall (0,81 contra 0,98), ou seja, o modelo erra principalmente marcando radiografias normais como suspeitas.

É exatamente o comportamento que se espera ao levar um modelo de um hospital para outro — e a razão pela qual a seção 11 insiste em validação prospectiva local e monitoramento de deriva. Um modelo que só fosse avaliado na própria validação teria reportado 0,997 e escondido esse problema.

Note ainda que, aqui, o limiar clínico calibrado **piorou** acurácia e F1 em troca de 2 falsos negativos a menos. A troca é defensável em triagem — mas mostra que baixar o limiar não é gratuito, e que a decisão precisa ser tomada com o custo real em mãos.

10.4 Interpretabilidade visual — Grad-CAM

O **Grad-CAM** é o equivalente do SHAP para imagens: destaca as regiões que mais pesaram na decisão. Sua função aqui não é decorativa — é permitir que o radiologista verifique se a rede olhou para o **campo pulmonar** ou para um artefato irrelevante (borda da imagem, texto sobreposto, marcador metálico). Um modelo com métricas excelentes e mapa de ativação na borda da imagem é um modelo que aprendeu o dataset, não a doença.

(figs. `33_cnn_predicoes.png`, `34_cnn_gradcam.png`)

11. Discussão crítica: dá para usar na prática?

Sim — mas com escopo restrito, como apoio, e nunca como decisor.

11.1 Como usar

Não como rótulo binário, e sim como **fila com três faixas** (seção 7.4). O ganho não é "acertar o diagnóstico": é **reordenar a fila** para que os casos graves sejam vistos primeiro e **tornar a incerteza explícita** em vez de escondê-la atrás de um rótulo.

O laudo de apoio (`scripts/predict.py`) entrega, para cada exame: probabilidade, faixa, conduta sugerida e a explicação SHAP individual. Toda saída carrega o aviso de que a palavra final é do médico.

11.2 Limitações que impedem uso imediato

1. **Amostra pequena e de fonte única.** 569 biópsias de um único centro (Wisconsin, anos 1990). O intervalo de confiança sobre 114 exames de teste é largo: a diferença entre 0,95 e 0,98 de recall são **dois pacientes**. Nenhuma métrica aqui autoriza implantação sem revalidação prospectiva local.
2. **As variáveis não caem do céu.** As 30 medidas pressupõem segmentação digital do núcleo celular a partir da lâmina. Sem essa etapa padronizada e calibrada, o modelo não tem entrada válida — e desvio de calibração entre equipamentos degrada o desempenho **silenciosamente**, sem lançar erro.
3. **Ausência de dados demográficos.** Não há idade, etnia ou histórico familiar, então **não é possível auditar o modelo por subgrupo**. Sem essa auditoria, não se pode afirmar que ele é igualmente seguro para todas as pacientes — e essa é uma condição inegociável em saúde.
4. **Limiar derivado de 43 casos positivos.** Como discutido na seção 6.2, sua precisão é limitada pela granularidade da amostra.
5. **Deslocamento de distribuição.** Novo microscópio, novo protocolo de coloração ou nova equipe mudam a distribuição das medidas. Sem monitoramento, a degradação é invisível.
6. **Vieses históricos da base.** Um modelo treinado em dados dos anos 1990 herda os critérios de encaminhamento daquela época e daquela população.

11.3 Requisitos para uma implantação responsável

requisito	por quê
Validação prospectiva local antes de qualquer uso	as métricas deste relatório não se transferem automaticamente
Limiar homologado pelo comitê clínico	a troca recall × precisão é uma decisão médica e institucional, não técnica
Registro auditável de toda predição com sua explicação SHAP	exigência regulatória e condição para investigar erros
Monitoramento de deriva (distribuição dos scores e taxa de alarme)	detectar mudança de equipamento ou protocolo antes que ela cause dano
Botão de discordância para o médico, realimentando o treino	mantém o profissional no controle e gera dados de melhoria
Auditoria por subgrupo assim que houver dados demográficos	garantir desempenho equitativo
Reavaliação periódica obrigatória	modelo clínico não é software que se instala e esquece

12. Conclusão

O pipeline entrega o que a Fase 1 pediu e sustenta as afirmações com números reproduzíveis:

- **exploração** completa, com auditoria de qualidade e leitura clínica das distribuições;
- **pré-processamento** em `Pipeline`, com ramos numérico e categórico, à prova de vazamento e testado contra dados ausentes e categorias inéditas;
- **seis modelos** com busca de hiperparâmetros e separação rigorosa treino/validação/teste;
- **métrica escolhida a partir do custo clínico do erro**, e limiar tratado como parâmetro médico e não como convenção;
- **interpretação** por três lentes convergentes, incluindo explicação individual por paciente;
- **entregável EXTRA** com CNN treinada do zero (ROC AUC 0,971 e recall 0,987 no teste) e Grad-CAM.

O resultado técnico mais relevante não é a métrica de topo — é que **o modelo mais simples e mais auditável empatou com os mais complexos**. Em um domínio onde a explicação vale tanto quanto o acerto, esse empate decide a escolha.

E o resultado mais importante é o que o sistema **não** faz: ele não diagnostica. Ele ordena a fila, quantifica a incerteza e mostra o próprio raciocínio.

O modelo prioriza. O médico diagnostica.

Anexo A — Figuras geradas pelo pipeline

Todas as figuras abaixo são produzidas automaticamente por `scripts/run_pipeline.py` e `scripts/run_cnn.py`, e ficam em `reports/figures/`.




Figura 1. Distribuição do alvo: 357 benignos (62,7%) e 212 malignos (37,3%). (01_balanceamento_classes.png)




Figura 2. Distribuicao das 9 variaveis mais discriminantes, separada por diagnostico. (02_distribuicoes_por_classe.png)




Figura 3. Dispersao e outliers por diagnostico. (03_boxplots_por_classe.png)




Figura 4. Correlacao entre as 30 preditoras; os blocos vermelhos sao os grupos redundantes. (04_matriz_correlacao.png)




Figura 5. Correlacao ponto-biserial de cada variavel com o diagnostico. (05_correlacao_com_alvo.png)




Figura 6. Projecao PCA: as classes ja se separam em duas dimensoes. (06_projecao_pca.png)




Figura 7. Dispersao pareada das variaveis mais discriminantes. (07_dispersao_pareada.png)




Figura 8. Escalas e assimetrias que justificam a padronizacao e a imputacao pela mediana. (08_escala_e_assimetria.png)




Figura 9. Comparacao dos seis modelos no conjunto de validacao. (09_comparacao_modelos.png)




Figura 10. Curvas ROC e Precisao-Recall dos seis modelos (validacao). (10_curvas_roc_pr.png)




Figura 11. Calibracao do limiar: trade-off recall x precisao e o ponto escolhido. (11_analise_limiar.png)

Matriz de confusao - Regressao Logistica (teste) (limiar = 0.500)




Figura 12. Matriz de confusao no teste com o limiar padrao de 0,50. (12_matriz_confusao_padrao.png)




Figura 13. Matriz de confusao no teste com o limiar clinico calibrado. (13_matriz_confusao_clinica.png)




Figura 14. Separacao das classes pela probabilidade prevista. (14_distribuicao_scores.png)




Figura 15. Curva de calibracao: a probabilidade prevista corresponde ao risco observado. (15_calibracao.png)




Figura 16. Curva de aprendizado do modelo campeão. (16_curva_aprendizado.png)




Figura 17. Coeficientes do modelo campeão (positivo empurra para maligno). (*17_importancia_nativa.png*)




Figura 18. Modelo de referencia interpretavel: coeficientes da regressao logistica. (18_referencia_logistica.png)




Figura 19. Queda real de ROC AUC ao embaralhar cada variavel. (*19_importancia_permutacao.png*)




Figura 20. SHAP beeswarm: magnitude e direcao do efeito de cada variavel. (20_shap_beeswarm.png)




Figura 21. Importancia global SHAP (media do valor absoluto). (21_shap_importancia_global.png)




Figura 22. Explicacao individual - caso corretamente sinalizado como maligno. (22_3_shap_caso_verdadeiro_positivo.png)




Figura 23. Explicacao individual - falso positivo. (22_2_shap_caso_falso_positivo.png)




Figura 24. Explicacao individual - falso negativo (o erro mais grave). (22_1_shap_caso_falso_negativo.png)




Figura 25. Explicacao individual - caso ambiguo, proximo do limiar. (22_4_shap_caso_caso_ambiguo.png)




Figura 26. EXTRA: exemplos do PneumoniaMNIST. (30_amostras_radiografias.png)




Figura 27. EXTRA: evolução da perda e da ROC AUC ao longo das épocas. (31_cnn_curvas_treino.png)




Figura 28. EXTRA: matriz de confusão da CNN no teste. (32_cnn_matriz_confusao.png)

Predicoes da CNN no conjunto de teste
(vermelho = erro; erros mais confiantes aparecem primeiro)




Figura 29. EXTRA: predicoes da CNN (erros mais confiantes primeiro). (33_cnn_predicoes.png)

Onde a CNN olhou para decidir
(linha de cima: radiografia original | linha de baixo: mapa de ativacao)




Figura 30. EXTRA: Grad-CAM - onde a rede olhou para decidir. (34_cnn_gradcam.png)